

Linear Probe AUC for Harmfulness Detection
(category='all'; chance = 0.5)

